



Universidad de Concepción

Facultad de Ingeniería

Departamento de Ingeniería Eléctrica

Procesamiento Digital de Imágenes

549452-1

Vincenzo Caro Fuentes

MiniProyecto 2

José Aldea Gómez

Nelson Marillán

11 de noviembre de 2026

Índice general

1. Introducción **2**

2. Ítem 1.1: Adquisición y construcción del dataset **3**
2.1. Objetivo y clases de interés 3
2.2. Adquisición y organización de las fotografías 3

3. Ítem 1.2: Preparación y extracción de características **4**
3.1. 1.2.1 Preparación de imágenes y extracción de ROI 4
3.2. 1.2.2 Identificación y extracción de características visuales 4
3.3. 1.2.3 Comparación numérica de texturas 4
3.4. 1.2.4 Construcción de vectores de características 5

4. Ítem 1.3: Construcción y entrenamiento de estrategias **6**
4.1. 1.3.1 Estrategia A: Píxeles aplanados (Flatten) 6
4.2. 1.3.2 Estrategia B: Píxeles aplanados y PCA 6
4.3. 1.3.3 Estrategia C: Descriptores de textura 7
4.4. 1.3.4 Algoritmo clásico de clasificación 7
4.5. 1.3.5 Diagrama de Flujo del Procedimiento 8

5. Ítem 1.4: Evaluación y comparación de resultados **9**
5.1. 1.4.1: Resultado de la estrategia A 9
5.2. 1.4.2: Resultado de la estrategia B 9
5.3. 1.4.3: Resultado de la estrategia C 10
5.4. 1.4.4: Comparación global y dimensiones 10
5.5. 1.4.5: Importancia de características de textura 11

6. Conclusiones **13**

7. Anexo: Código utilizado **14**

Introducción

Este MiniProyecto tiene como objetivo desarrollar un clasificador capaz de identificar ocho tipos de telas a partir de imágenes microscópicas, analizando principalmente las características de sus texturas.

Para ello, se construyó un dataset de fotografías, de las cuales se extrajeron regiones de interés (ROI). Estas fueron procesadas en escala de grises y mediante un filtro promedio 3x3. Posteriormente, se aplicaron las técnicas GLCM, LBP, Gabor y Laws para obtener características numéricas de las texturas.

Finalmente, se implementaron tres estrategias de clasificación utilizando Random Forest, con el propósito de comparar sus resultados y determinar cuál permite diferenciar mejor los tipos de telas.

Ítem 1.1: Adquisición y construcción del dataset

2.1. Objetivo y clases de interés

El objetivo de este MiniProyecto es clasificar ocho tipos de telas mediante el análisis de sus características visuales, principalmente las texturas que presentan sus fibras en imágenes microscópicas.

Para esto, se identificaron ocho clases, denominadas Tela 1 hasta Tela 8, las cuales presentan diferencias en sus patrones y estructuras.

2.2. Adquisición y organización de las fotografías

Se construyó un dataset compuesto por 127 fotografías originales, organizadas en carpetas según el tipo de tela al que pertenecen.

La cantidad de fotografías disponibles no fue igual para todas las clases, como se muestra en la siguiente tabla.

Tabla 2.1: Distribución de fotografías por clase.

Clase	**Fotografías**
Tela 1	21
Tela 2	18
Tela 3	27
Tela 4	26
Tela 5	9
Tela 6	5
Tela 7	15
Tela 8	6
Total	**127**

Esta diferencia en la cantidad de fotografías es importante, ya que las clases con menos imágenes proporcionan menos ejemplos para que el clasificador aprenda sus características, lo que podría afectar sus resultados.

Ítem 1.2: Preparación y extracción de características

3.1. 1.2.1 Preparación de imágenes y extracción de ROI

Para comenzar el procesamiento, de cada fotografía original se extrajeron cuatro regiones de interés (ROI), ubicadas en distintas zonas de la imagen.

Esto permitió analizar diferentes sectores de una misma tela, obteniendo un total de 508 ROI a partir de las 127 fotografías originales.

Posteriormente, las ROI se redimensionaron a 180x180 píxeles y se convirtieron a escala de grises, ya que nuestro objetivo es analizar las diferencias de intensidad y las características de textura.

Finalmente, se aplicó un filtro promedio de 3x3, con el propósito de suavizar pequeñas variaciones de intensidad y reducir el ruido presente en las imágenes.

3.2. 1.2.2 Identificación y extracción de características visuales

Una vez procesadas las ROI, se aplicaron cuatro técnicas de extracción de características: GLCM, LBP, Gabor y Laws.

Cada técnica permite analizar diferentes propiedades de la textura:

- **GLCM:** analiza la relación entre las intensidades de los píxeles vecinos, permitiendo obtener propiedades como contraste y homogeneidad.
- **LBP:** analiza patrones locales de textura mediante la comparación de un píxel central con sus vecinos.
- **Gabor:** permite analizar estructuras de la textura según distintas orientaciones.
- **Laws:** utiliza máscaras para analizar variaciones espaciales de intensidad, como las relacionadas con bordes.

Estas cuatro técnicas se aplicaron de manera independiente sobre las ROI procesadas. Posteriormente, sus resultados numéricos se combinaron para obtener una descripción más completa de cada región.

3.3. 1.2.3 Comparación numérica de texturas

Después de aplicar las técnicas anteriores, se obtuvieron descriptores numéricos que permiten comparar las características de las telas.

La siguiente tabla presenta los valores calculados a partir de la primera ROI de cada clase.

Tabla 3.1: Comparación de descriptores numéricos por clase.

Clase	Contraste	Homogeneidad	LBP uniforme	LBP no uniforme	Gabor 0°	Laws L5E5
Tela 1	0,615	0,752	0,912	0,088	2,020	4,642
Tela 2	0,470	0,797	0,912	0,087	1,543	3,672
Tela 3	0,839	0,746	0,912	0,088	1,974	4,830
Tela 4	0,591	0,762	0,917	0,083	1,882	4,447
Tela 5	0,532	0,774	0,907	0,093	1,773	3,975
Tela 6	1,347	0,644	0,951	0,049	3,281	7,350
Tela 7	0,630	0,753	0,905	0,095	2,021	4,715
Tela 8	1,111	0,698	0,915	0,085	2,554	5,761

Por ejemplo, la ROI de la Tela 6 presenta el contraste más alto (1,347) y la homogeneidad más baja (0,644) de la tabla. Esto indica que existen diferencias de intensidad más marcadas entre sus píxeles vecinos.

Además, presenta un 95,1 % de patrones LBP uniformes, lo que significa que esa proporción de patrones cumple la condición de tener como máximo dos transiciones entre ceros y unos.

También se observan las respuestas más altas en Gabor 0° y Laws L5E5, lo que permite distinguir esta ROI de las demás muestras comparadas.

Estos valores muestran cómo las técnicas utilizadas permiten describir numéricamente distintas propiedades de la textura.

3.4. 1.2.4 Construcción de vectores de características

Finalmente, los descriptores numéricos obtenidos mediante las cuatro técnicas se combinaron en un único vector de características para cada ROI.

La cantidad de valores aportados por cada técnica fue la siguiente:

- **GLCM:** 16 valores, correspondientes a cuatro propiedades calculadas en cuatro direcciones.
- **LBP:** 10 valores, correspondientes a nueve categorías de patrones uniformes y una categoría de patrones no uniformes.
- **Gabor:** 8 valores, obtenidos mediante la media y desviación estándar de las respuestas en cuatro orientaciones.
- **Laws:** 12 valores, correspondientes a la media y desviación estándar de seis máscaras.

Por lo tanto, cada ROI quedó representada por un vector de 46 características numéricas.

Estos vectores permiten representar las propiedades de textura de las imágenes y posteriormente son utilizados como entrada del clasificador Random Forest en la estrategia C.

Ítem 1.3: Construcción y entrenamiento de estrategias

4.1. 1.3.1 Estrategia A: Píxeles aplanados (Flatten)

La primera estrategia consistió en utilizar directamente los valores de intensidad de cada ROI procesada. Cada imagen fue convertida en un vector unidimensional mediante la operación *flatten*, conservando la información de intensidad de todos sus pixeles.

Dado que cada ROI posee dimensiones de 180 x 180 pixeles, cada muestra quedo representada por un vector de:

$$180 \times 180 = 32400 \text{ pixeles}$$

Estos vectores fueron utilizados como entrada de un clasificador *Random Forest*. El objetivo de esta estrategia fue establecer una linea base utilizando unicamente la información de intensidad de los pixeles, sin aplicar técnicas adicionales de reducción de dimensionalidad ni extracción de características.

4.2. 1.3.2 Estrategia B: Píxeles aplanados y PCA

La segunda estrategia utilizo los mismos vectores de pixeles obtenidos mediante *flatten*. Sin embargo, antes de realizar la clasificación se aplico el algoritmo de Análisis de Componentes Principales (PCA).

El objetivo del PCA fue reducir la dimensionalidad del problema eliminando las redundancias presentes entre los pixeles vecinos y conservando la mayor cantidad posible de información relevante.

Se selecciono un numero de componentes capaz de preservar aproximadamente el 95 % de la varianza del conjunto de entrenamiento. Como resultado, la representación de cada ROI se redujo desde 32400 características hasta 170 componentes principales.

Posteriormente, estos vectores reducidos fueron utilizados como entrada para el clasificador *Random Forest*.

4.3. 1.3.3 Estrategia C: Descriptores de textura

La tercera estrategia utilizo exclusivamente los descriptores de textura obtenidos mediante las técnicas GLCM, LBP, Gabor y Laws.

Cada ROI fue representado mediante un vector de 46 características numéricas, compuesto por:

- 16 características GLCM.
- 10 características LBP.
- 8 características Gabor.
- 12 características Laws.

Esta representación busca describir propiedades relevantes de la textura, tales como contraste, homogeneidad, patrones locales y respuestas orientadas, utilizando una cantidad significativamente menor de datos que la representación basada en pixeles.

Los vectores resultantes fueron utilizados como entrada para el clasificador *Random Forest*.

4.4. 1.3.4 Algoritmo clásico de clasificación

Para las 3 estrategias se utilizo el algoritmo *Random Forest* como método de clasificación.

Random Forest es un conjunto de arboles de decisión que realiza la predicción final mediante votación entre múltiples clasificadores individuales. Este enfoque permite reducir el sobre ajuste y mejorar la capacidad de generalización respecto a un único árbol de decisión.

El mismo clasificador fue empleado en las 3 estrategias con el objetivo de realizar una comparación justa entre las distintas representaciones de las imágenes. De esta forma, las diferencias observadas en el rendimiento pueden atribuirse principalmente a la información utilizada como entrada y no al algoritmo de clasificación.

4.5. 1.3.5 Diagrama de Flujo del Procedimiento

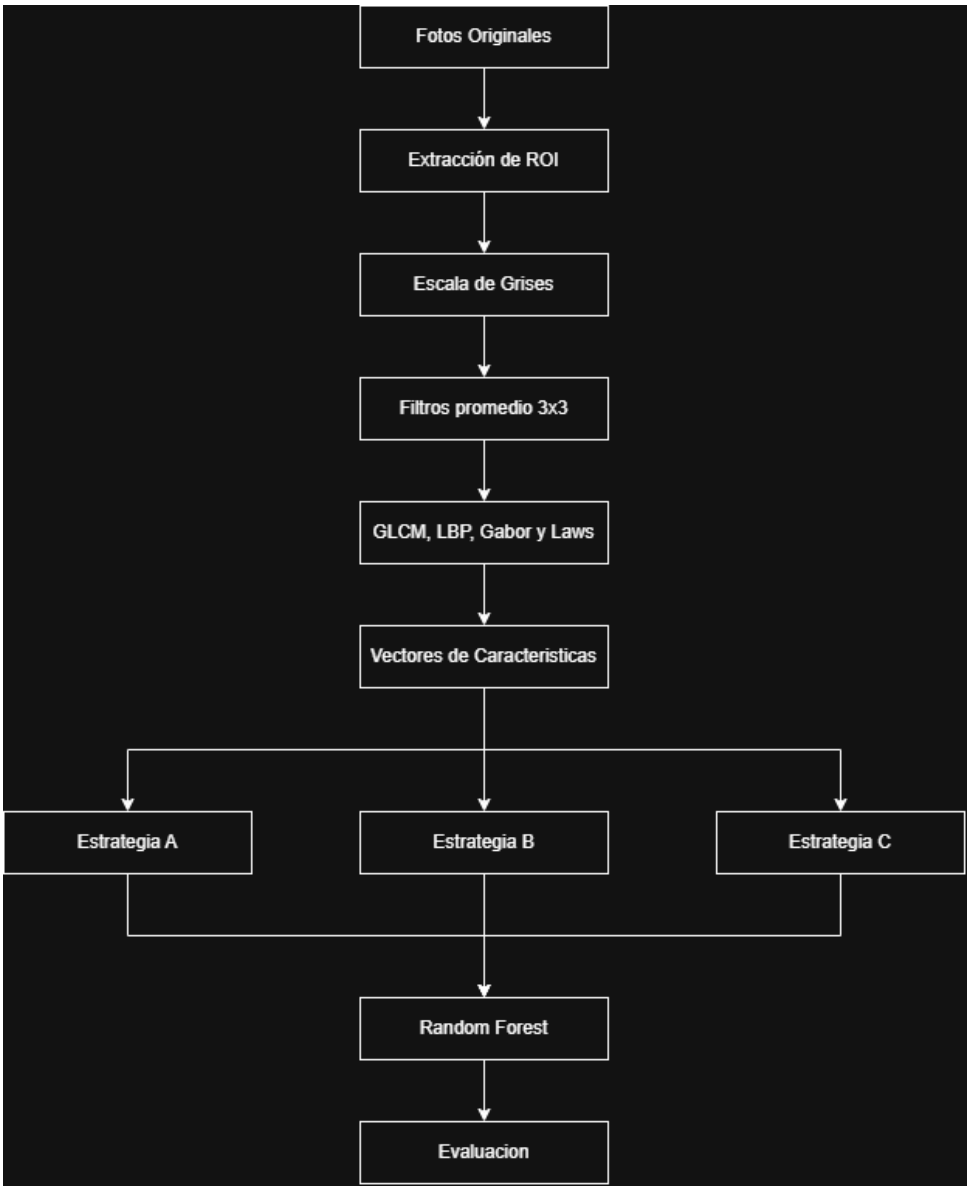


Figura 4.1: Diagrama general del procedimiento utilizado para la clasificación de telas.

Ítem 1.4: Evaluación y comparación de resultados

Para evaluar las tres estrategias de clasificación, se utilizó un 80 % de las fotografías para entrenamiento y un 20 % para pruebas.

La división se realizó considerando las fotografías originales, evitando que las ROI de una misma fotografía aparecieran en ambos conjuntos.

De esta manera, se utilizaron 404 ROI para entrenamiento y 104 ROI para pruebas.

Los resultados se analizaron mediante exactitud (*accuracy*), precisión, *recall*, F1-score y matrices de confusión.

5.1. 1.4.1: Resultado de la estrategia A

La estrategia A consistió en utilizar directamente los valores de intensidad de cada ROI en escala de grises.

Como cada ROI tiene un tamaño de 180x180 píxeles, se obtuvo un vector de 32400 características.

Esta estrategia alcanzó una exactitud de 82,69 %, con una precisión macro de 74,58 %, un recall macro de 77,14 % y un F1-score macro de 75,70 %.

En general, el clasificador logró identificar correctamente una parte importante de las telas. Sin embargo, también se observaron errores entre algunas clases.

Por ejemplo, cuatro ROI de la Tela 1 fueron clasificadas como Tela 4. Además, ninguna de las cuatro ROI de prueba de la Tela 8 fue clasificada correctamente.

Esto muestra que utilizar directamente los píxeles permite obtener resultados aceptables, aunque presenta dificultades para diferenciar ciertas clases.

5.2. 1.4.2: Resultado de la estrategia B

La estrategia B utilizó los píxeles de las ROI y posteriormente aplicó PCA para reducir la cantidad de características.

Con esta técnica, se pasó de 32400 características a 170 componentes principales, conservando aproximadamente el 95,01 % de la varianza de los datos de entrenamiento.

Esta estrategia obtuvo una exactitud de 93,27 %, una precisión macro de 83,05 %, un recall macro de 85,68 % y un F1-score macro de 84,28 %.

Estos resultados fueron los mejores entre las tres estrategias evaluadas.

Esto indica que, para nuestro conjunto de prueba, la reducción de dimensionalidad mediante

PCA permitió mantener información útil para diferenciar las telas.

Sin embargo, al igual que en la estrategia anterior, ninguna de las ROI de prueba de la Tela 8 fue clasificada correctamente.

5.3. 1.4.3: Resultado de la estrategia C

La estrategia C utilizó los descriptores numéricos obtenidos mediante GLCM, LBP, Gabor y Laws.

Como se explicó anteriormente, estas técnicas permiten representar cada ROI mediante un vector de 46 características de textura.

Esta estrategia obtuvo una exactitud de 89,42 %, una precisión macro de 80,21 %, un recall macro de 83,02 % y un F1-score macro de 81,54 %.

Aunque su exactitud fue menor que la obtenida con PCA, superó el resultado de la estrategia A.

Esto demuestra que los descriptores de textura permiten diferenciar las telas utilizando una cantidad mucho menor de características que los píxeles originales.

Entre los errores observados, dos ROI de la Tela 3 fueron clasificadas como Tela 1 y otras dos ROI de la Tela 4 también fueron clasificadas como Tela 1.

La Tela 8 volvió a presentar dificultades, ya que ninguna de sus cuatro ROI de prueba fue clasificada correctamente.

5.4. 1.4.4: Comparación global y dimensiones

Para comparar las tres estrategias, se consideraron sus métricas de clasificación y la cantidad de características utilizadas.

La Tabla 5.1 muestra los resultados generales obtenidos.

Tabla 5.1: Comparación de métricas de las tres estrategias.

Estrategia	**Accuracy**	**Precisión macro**	**Recall macro**	**F1 macro**
A - Flatten	82,69 %	74,58 %	77,14 %	75,70 %
B - PCA	93,27 %	83,05 %	85,68 %	84,28 %
C - Textura	89,42 %	80,21 %	83,02 %	81,54 %

Como se observa, la estrategia B obtuvo el mejor resultado tanto en exactitud como en F1-score macro.

Por otro lado, la estrategia C también consiguió un buen resultado utilizando solamente 46 características.

La Tabla 5.2 presenta las dimensiones de entrada de cada estrategia.

Tabla 5.2: Cantidad de características utilizadas.

Estrategia	Dimensiones	Reducción respecto a A
A - Flatten	32400	0,00 %
B - PCA	170	99,48 %
C - Textura	46	99,86 %

Estos resultados muestran que una mayor cantidad de características no necesariamente significa una mejor clasificación.

En nuestro caso, PCA obtuvo el mejor rendimiento, mientras que la estrategia de textura permitió reducir considerablemente la cantidad de datos utilizados por el clasificador.

También es importante considerar que algunas clases tienen pocas fotografías originales, especialmente las Telas 6 y 8.

Esto limita la cantidad de ejemplos disponibles para evaluar el comportamiento del clasificador. Por lo tanto, los resultados obtenidos corresponden a esta división de entrenamiento y prueba y no garantizan el mismo rendimiento con imágenes nuevas.

5.5. 1.4.5: Importancia de características de textura

Finalmente, se analizó la importancia de los 46 descriptores utilizados en la estrategia C.

Esta importancia se obtuvo mediante Random Forest y permite conocer qué características tuvieron mayor influencia en las decisiones del clasificador.

La Tabla 5.3 muestra la importancia acumulada y promedio de cada familia de descriptores.

Tabla 5.3: Importancia de las familias de textura.

Técnica	Importancia acumulada	Importancia promedio
GLCM	0,3407	0,0213
LBP	0,2722	0,0272
Gabor	0,1138	0,0142
Laws	0,2733	0,0228

Al observar la importancia acumulada, GLCM presenta el valor más alto, con 0,3407.

Sin embargo, estas técnicas no aportan la misma cantidad de características, por lo que también es importante considerar la importancia promedio.

En este caso, LBP presenta el promedio más alto, con 0,0272 por característica.

Entre los descriptores individuales más importantes se encuentran:

- LBP código 5, con una importancia de 0,0446.
- Laws W5W5 media, con una importancia de 0,0422.
- Laws S5S5 media, con una importancia de 0,0400.

Esto indica que los patrones locales de LBP y determinadas variaciones espaciales analizadas por Laws tuvieron una participación importante en las decisiones del clasificador.

De todas formas, estos valores representan la importancia estimada por Random Forest durante el entrenamiento, por lo que no significan que una característica sea necesariamente la más importante para cualquier conjunto de telas.

En general, este análisis permite identificar qué descriptores aportaron más información al modelo de clasificación basado en textura.

Conclusiones

En este MiniProyecto se desarrolló un sistema de clasificación para ocho tipos de telas utilizando imágenes microscópicas y distintas estrategias de representación de características. A partir de las fotografías originales, se extrajeron regiones de interés (ROI), las cuales fueron procesadas y utilizadas para construir distintos conjuntos de datos de entrenamiento y prueba.

Se evaluaron 3 estrategias de clasificación basadas en *Random Forest*. La estrategia A utilizó directamente los píxeles de las imágenes, la estrategia B aplicó reducción de dimensionalidad mediante PCA sobre dichos píxeles y la estrategia C empleó descriptores de textura obtenidos mediante las técnicas GLCM, LBP, Gabor y Laws.

Los resultados obtenidos muestran que la estrategia B presentó el mejor desempeño, alcanzando una exactitud de 93,27 %. Esto indica que la reducción de dimensionalidad mediante PCA permitió conservar la información más relevante de las imágenes y mejorar la capacidad de clasificación. Por otra parte, la estrategia C alcanzó una exactitud de 89,42 %, utilizando únicamente 46 características, lo que demuestra que los descriptores de textura contienen información representativa para diferenciar los distintos tipos de telas.

Además, el análisis de importancia de características mostró que los descriptores provenientes de GLCM, LBP y Laws tuvieron una contribución significativa en las decisiones del clasificador, destacando especialmente algunos patrones locales de LBP y ciertas respuestas obtenidas mediante leyes de textura de Laws.

Finalmente, se observó que las clases con menor cantidad de fotografías disponibles presentaron mayores dificultades de clasificación, especialmente la Tela 8. Esto sugiere que una mayor cantidad de muestras podría mejorar la capacidad de generalización del modelo. Como trabajo futuro, sería interesante ampliar el conjunto de datos y evaluar otros algoritmos de clasificación para analizar posibles mejoras en el rendimiento.

Anexo: Código utilizado

https://github.com/Joseeeeeeeeeeeeeeee/mini-proyecto-2---PDI